

主机 / CPU 内存

host pointer 输入
CPU侧查询 / 向量

主机侧结果
索引 / 距离回传

CPU→GPU 拷贝

结果回传主机

GPU显存 / GPU索引

device pointer 输入
GPU侧查询 / 向量

同GPU: 无拷贝

FAISS-GPU 索引
GPU上 search() / add()

同GPU输入
无需拷贝

跨设备输入
发生跨设备拷贝

GPU Index 可接收 host pointer 与 device pointer。输入与索引位于同一GPU时无需拷贝；否则会触发 CPU→GPU 或跨设备拷贝，并在需要时将结果返回主机。