

离线准备

统一向量化样本库 $\{v_1, v_2, \dots, v_n\}$

索引离线构建

索引构建 GPU-resident 或 out-of-core

候选索引 I 支持大规模 ANN 检索

索引组织目标：低延迟定位局部候选邻域 并支持召回质量 / 吞吐折中

在线候选召回执行

查询样本向量 v_i

召回参数配置 $|C_i|$ 、 k_recall 、检索深度

在线查询路径

FlashANNS 候选召回执行 异步 I/O—计算流水线

局部候选扩展与维护 距离计算 / 候选筛选 / 邻域更新

设备侧候选结果组织 避免大量 CPU 侧重组

召回质量—吞吐平衡 候选过小：异常覆盖不足 候选过大：后续评分负担上升

候选输出与后续衔接

候选输出字段 ID / distance / local rank / reference

候选集合 C_i

直接传递至 PyTOD 评分模块 作为后续精排评分输入