

GPU 侧连续传递主路径

评分中间张量：
distance matrix / local sorting / aggregation stats

CPU / 主机侧

统一查询向量
 $v_i \in \mathbb{R}^d$

候选召回模块
FlashANNS / FAISS-GPU

候选结果缓冲
ID / distance / local rank /
reference

候选组织与重排

PyTOD 评分主干

最终小规模结果
score / rank / logs

输入：查询向量

输出：候选集合 C_i

形成可直接进入评分的设备侧张量

查询向量、候选结果与评分中间张量尽量保留在 GPU 侧连续流转

仅最终结果与日志回传主机

模块间传递对象

① 查询向量 v_i

② 候选结果 C_i 及其字段

③ 候选张量 / index mapping

④ 评分中间张量

⑤ 最终结果与日志